

RAG 检索增强生成基础知识标准化文档

目录

RAG 检索增强生成基础知识标准化文档	1
1 RAG 基础定义、诞生背景与核心价值	1
1.1 通用定义	1
1.2 诞生背景（原生 LLM 三大缺陷）	1
1.3 四大核心优势	1
1.4 基础交互逻辑	1
2 RAG 两大标准运行阶段：离线索引+在线推理	2
2.1 阶段一：离线索引（Offline Indexing，知识库预处理）	2
2.2 阶段二：在线推理（Online Inference，用户问答实时链路）	2
2.3 两阶段核心区分表	2
3 RAG 全链路六大核心组件详解	3
3.1 Document Loader 文档加载器（数据源入口）	3
3.2 Text Splitter 文本分块切片器	3
3.3 Embedding 向量化嵌入模型（语义转换器）	3
3.4 Vector Store 向量数据库（知识存储核心）	3
3.5 Retriever+Rerank 检索器+重排序模块	4
3.6 LLM 生成器（答案输出中枢）	4
4 RAG 主流技术架构分类	5
4.1 基础朴素 RAG（Naive RAG）	5
4.2 进阶优化 RAG（Advanced RAG）	5
4.3 Graph RAG 图谱增强 RAG	5
4.4 Agentic RAG 智能体 RAG（LLM-Agent+RAG 融合）	5
4.5 多模态 RAG	5
5 RAG 标准执行七步闭环流程	6
5.1 Query Preprocess 查询预处理	6
5.2 Multi-Retrieve 多路联合召回	6
5.3 Rerank 重排序降噪	6
5.4 Context Compress 上下文压缩	6
5.5 Prompt Augment 增强提示词拼接	6
5.6 LLM Generate 答案生成	6
5.7 Result Output & Archive 结果输出与归档	6

6 主流检索优化增强技术	8
6.1Query Rewrite 查询改写	8
6.2HyDE（假设性文档嵌入）	8
6.3RRF 倒数排名融合	8
6.4Parent-Document 父子检索	8
6.5Self-Query RAG 自查询检索	8
7 RAGvs 纯大模型微调 vs 传统检索核心差异对比	9
8 RAG 与 LLM-Agent 智能体关联与区别	10
8.1 基础关联	10
8.2 核心差异对比	10
8.3 组合使用标准范式	10
9 企业落地行业应用场景	11
9.1 政企政务领域	11
9.2 企业办公客服领域	11
9.3 金融法律领域	11
9.4 医疗科研领域	11
9.5 工业制造领域	11
9.6 教育培训领域	11
10 最简 RAG 开发工业伪代码	12
11 RAG 专业术语词典	14

1 RAG 基础定义、诞生背景与核心价值

1.1 通用定义

RAG 全称 Retrieval-Augmented Generation，检索增强生成，是将外部知识库检索与大语言模型文本生成结合的标准化 AI 技术架构。

核心逻辑：先从私有/外部知识库检索事实文本，将检索片段与用户问题拼接送入 LLM，依托真实资料生成回答，解决原生大模型知识滞后、幻觉、私有数据不可用三大痛点

技术体系划分：(1)基础 RAG：单轮向量检索+单次生成，轻量化知识库问答；(2)进阶 RAG：混合检索、重排序、查询改写、多轮召回；(3)Agentic RAG（智能体 RAG）：融合 LLM-Agent 规划、多跳检索、工具联动，适配复杂多步骤查询。

1.2 诞生背景（原生 LLM 三大缺陷）

1.知识截止固定：大模型训练数据存在时间边界，无法获取最新政策、企业内部文档、实时业务数据；

2.幻觉问题严重：无外部事实约束时，模型自主编造不存在数据、法条、参数；

3.私有数据隔离：企业合同、工单、病历等内部资料无法写入模型参数，直接提问无对应知识。

1.3 四大核心优势

1.低幻觉、可溯源：答案全部绑定原文文档、页码、来源，支持事实核验；

2.知识动态更新：新增文档仅需重新向量化入库，无需重训 / 微调模型；

3.数据安全可控：私有文件本地向量库存储，无需上传至第三方大模型；

4.低成本落地：对比大模型微调，无需海量标注数据、不占用高额算力。

1.4 基础交互逻辑

闭环流转链路：用户查询→检索预处理模块→向量数据库召回文本块→上下文 Prompt 组装→LLM 生成回答→输出带引用结果

2 RAG 两大标准运行阶段：离线索引+在线推理

行业通用二分架构，完全解耦，可分开部署、独立迭代优化

2.1 阶段一：离线索引（Offline Indexing，知识库预处理）

作用：将原始文档转为向量索引持久存储，离线批量执行，不影响线上问答响应速度。

标准流程：多源文档加载→数据清洗脱敏→文本分块切片→Embedding 向量化编码→向量+元数据存入向量数据库

配套元数据：文件名称、页码、文档类型、更新时间、业务标签，用于检索过滤、溯源展示。

2.2 阶段二：在线推理（Online Inference，用户问答实时链路）

作用：用户提问后实时执行检索+生成，毫秒级响应

标准流程：用户输入查询→查询改写优化→多路召回检索→结果重排序过滤噪声→检索片段拼接 Prompt→LLM 生成答案→附加文档引用输出

2.3 两阶段核心区分表

阶段	执行时机	算力消耗	执行频率	核心输出物
离 线 索 引	文档新增 / 更新时	高（批量向量化）	低频，定时增量更新	向量索引库、分块文本元数据
在 线 推 理	用户实时提问	低（单次检索生成）	高频，并发访问	带资料引用的问答结果

3 RAG 全链路六大核心组件详解

商用/开源 RAG 系统统一标准化组件，模块解耦可单独替换选型

3.1 Document Loader 文档加载器（数据源入口）

功能：解析多格式原始文件，提取纯文本、表格、图片 OCR 内容主流选型：

文本类：TextLoader、MarkdownLoader；

版式文件：PyPDFLoader、MinerU（复杂 PDF 双栏/表格识别）；

网页/接口：WebBaseLoader、API 文档加载器；

结构化数据：ExcelLoader、CSVLoader。

3.2 Text Splitter 文本分块切片器

功能：超长文档切割为固定长度语义块（Chunk），匹配 Embedding 模型输入上限，设置重叠窗口避免上下文断裂 主流切片方案：

固定字符切片：简易场景，通用性强；

递归字符切片：按段落/标题分层切割，工业基础方案；

语义切片：通过向量相似度自动分割语义边界，法律、论文高精度场景；

父子分块：粗粒度父块+细粒度子块，兼顾检索精度与上下文完整性。

3.3 Embedding 向量化嵌入模型（语义转换器）

功能：将文本 Chunk 转换为低维数字向量（语义指纹），语义相近文本向量空间距离更近主流选型：

开源中文：BGE-M3、Qwen-Embedding-V2、m3e；

闭源商用：text-embedding-3、通义 Embedding；使用规范：禁止使用生成式 LLM 充当 Embedding，算力高、语义匹配效果差。

3.4 Vector Store 向量数据库（知识库存储核心）

功能：存储文本向量+对应原文元数据，提供高效相似度检索、过滤、增量更新 分类与选型：

轻量本地：FAISS、Chroma（实训、单机轻量化项目）；

企业分布式：Milvus、Qdrant、PgVector（生产并发、百万级文档）；

核心能力：向量相似度检索、元数据条件过滤、批量插入、索引加速。

3.5 Retriever+Rerank 检索器+重排序模块

检索器：多路召回（向量语义检索+关键词 BM25 检索），召回 Top-K 候选文本；

重排序 Rerank：交叉编码器模型对候选块二次打分，过滤无关噪声，输出 Top3-Top5 高相关片段，大幅提升问答准确率。

3.6 LLM 生成器（答案输出中枢）

功能：接收「用户问题+检索上下文」增强 Prompt，基于检索资料生成合规、可引用回答

配套约束 Prompt 模板：强制模型仅依托背景资料作答，无匹配资料直接告知无相关信息，禁止编造内容。

4 RAG 主流技术架构分类

4.1 基础朴素 RAG (Naive RAG)

最简落地架构，仅执行「向量单路检索+单次生成」，无查询改写、重排序优化；

适用场景：小型内部知识库、简单 FAQ 问答、课程实训；

缺陷：模糊问句召回精度低，多文档关联问题效果差。

4.2 进阶优化 RAG (Advanced RAG)

在基础架构上叠加全套优化链路：查询改写、HyDE 假设文档嵌入、多路召回、RRF 融合、重排序、上下文压缩；

适用场景：企业客服、政务政策查询、内部文档检索；

优势：大幅降低漏召回、无关文本干扰，行业主流落地方案。

4.3 Graph RAG 图谱增强 RAG

融合知识图谱，将文档实体、关系构建网络节点；检索时沿实体关联链路多跳查找关联信息；

适用场景：金融产业链、医疗病症关联、设备运维台账、复杂因果分析；

特点：擅长处理多实体关联、跨文档串联类问题。

4.4 Agentic RAG 智能体 RAG (LLM-Agent+RAG 融合)

将检索封装为智能体工具，由 LLM 自主规划检索策略：拆解复杂子问题、多次检索、交叉验证资料、多轮补充查询；

适用场景：科研文献综述、法律合同综合分析、跨领域复杂业务咨询；

核心区别：基础 RAG 仅单次检索，Agentic RAG 支持自主多轮迭代检索。

4.5 多模态 RAG

扩展支持图片、表格、图纸、扫描件 OCR 向量检索，统一图文语义嵌入；

适用场景：工程图纸检索、产品图文手册、医疗影像报告、档案扫描件知识库。

5 RAG 标准执行七步闭环流程

完整线上问答标准链路，所有 RAG 框架通用标准化流程

5.1Query Preprocess 查询预处理

接收用户原始口语化提问，清洗无效符号、去除冗余语气词；执行查询改写，拆分多维度子查询，生成多条同义检索语句。

5.2Multi-Retrieve 多路联合召回

向量检索：基于 Embedding 语义匹配召回相似文本块；

关键词检索：BM25 精准匹配专业术语、编号、标题；两路结果融合去重，输出 Top-K 候选片段。

5.3Rerank 重排序降噪

使用交叉编码器模型对全部候选块打分，剔除低相关、无关文本，保留 3-5 条最高匹配度 Chunk。

5.4Context Compress 上下文压缩

对长检索片段精简提炼核心信息，控制总文本长度不超出 LLM 上下文窗口，减少冗余占用。

5.5Prompt Augment 增强提示词拼接

固定模板组装：约束指令+检索上下文原文+用户原始问题，输入大模型。

5.6LLM Generate 答案生成

LLM 严格依据提供的知识库内容输出回答，自动标注每条结论对应的文档来源、页码。

5.7Result Output & Archive 结果输出与归档

返回带引用溯源的完整答案；同步将本次问答、检索记录存入向量库长期记

忆，供后续相似问题复用。

6 主流检索优化增强技术

6.1 Query Rewrite 查询改写

LLM 将模糊口语问句转为标准化检索语句，同时生成多条同义查询，拓宽检索覆盖范围；

示例：用户问“年假怎么算”→改写为「公司年假计算规则、入职年假标准、年假天数规定」。

6.2 HyDE（假设性文档嵌入）

先让 LLM 生成该问题的假设性完整答案，将假设答案向量化后检索，解决简短问句语义向量匹配偏差问题，大幅提升模糊问题召回率。

6.3 RRF 倒数排名融合

向量检索、关键词检索两路结果加权融合，平衡语义匹配与关键词精准匹配，避免单一路召回遗漏关键资料。

6.4 Parent-Document 父子检索

检索细粒度子块定位匹配段落，读取完整父文档上下文，解决切片导致上下文断裂、信息不全问题。

6.5 Self-Query RAG 自查询检索

LLM 自动从用户问题提取过滤条件（时间、部门、文件类型），检索时附加元数据筛选，精准过滤无关文档。

7 RAGvs 纯大模型微调 vs 传统检索核心差异对比

技术方案	知 识 时 效 性	私 有 数 据 安 全	幻 觉 概 率	更 新 成 本	算 力 需 求	适 用 场 景
原 生 LLM 无 增 强	固 定 截 止 时 间	无 法 加 载 私 有 文 档	极 高	不 可 更 新	中	通 用 闲 聊、基 础 常 识 问 答
微 调 Fine-tune	固 定 训 练 时 间	训 练 数 据 上 传 模 型	中	高，需重 训	极高	标 准 化 固 定 输 出 风 格
传统关键词 检索	实 时 更 新	本 地 存 储 可 控	无 生 成 能 力	低	低	仅 关 键 词 匹 配，无 法 语 义 理 解
RAG 检索增 强生成	实 时 增 量 更 新	本 地 向 量 库 隔 离	极 低	极 低，仅 增 量 向 量 化	中低	企 业 知 识 库、政 策、 合 同、医 疗 等 高 合 规 场 景

核心通俗总结：微调是改模型参数记忆知识；传统检索只找文字不理解语义；RAG 是给大模型配专属实时私有搜索引擎，按需调取事实资料再生成。

8 RAG 与 LLM-Agent 智能体关联与区别

8.1 基础关联

RAG 是 Agent 标准内置核心工具模块，文档、知识库查询全部依托 RAG 实现；Agentic RAG 是二者融合进阶方案。

8.2 核心差异对比

维度	RAG 检索增强生成	LLM-Agent 智能体
核心定位	知识检索工具链路，解决事实问答	自主任务调度决策中枢，复杂任务拆解执行
自主能力	无自主规划，被动接收用户查询	自主拆分任务、多轮工具调用、动态调整执行逻辑
执行轮次	单轮检索 + 单次生成	多轮循环推理、检索、校验、重试
依赖组件	向量库、Embedding、重排序模型	规划引擎、记忆系统、工具集（RAG / 计算器 / 接口）
典型任务	文档问答、政策解读、资料查询	多步骤办公自动化、复杂科研分析、多角色协同业务

8.3 组合使用标准范式

复杂业务流程：Agent 规划拆解子任务→子任务涉及知识库查询时调用 RAG 工具→RAG 返回资料→Agent 汇总全部信息生成完整方案。

9 企业落地行业应用场景

9.1 政企政务领域

政策文件智能解读、行政审批知识库问答、法规合规校验、公文档案检索、政策新旧条文对比。

9.2 企业办公客服领域

产品手册智能问答、售后工单自动核查、合同条款检索、员工制度咨询、邮件/文档批量信息提取。

9.3 金融法律领域

信贷规则查询、保险条款解读、法律法条检索、合同风险比对、财报数据文档分析。

9.4 医疗科研领域

临床指南检索、论文文献综述、实验数据文档查询、病症诊疗资料匹配、医学知识库答疑。

9.5 工业制造领域

设备运维手册检索、产线工艺文档查询、故障解决方案知识库、工程图纸图文检索。

9.6 教育培训领域

教材知识点答疑、教学课件检索、题库资料匹配、学术论文辅助查阅。

10 最简 RAG 开发工业伪代码

轻量化基础 RAG 完整执行代码，注释清晰，适配入门实训

基础 Naive RAG 完整执行链路伪代码

```
def rag_pipeline(user_query: str):
    # 步骤 1: 文档预处理（离线阶段，仅新增文件执行）
    def build_knowledge_base(file_path):
        # 1.1 加载文档
        raw_text = DocumentLoader(file_path).load()

        # 1.2 文本分块切片
        splitter = RecursiveCharacterTextSplitter(chunk_size=500, overlap=80)
        text_chunks = splitter.split_text(raw_text)

        # 1.3 向量化编码
        embed_model = EmbeddingModel()
        chunk_vectors = embed_model.encode(text_chunks)

        # 1.4 存入向量数据库，绑定元数据
        vector_db.add_texts(texts=text_chunks, embeddings=chunk_vectors,
            metadatas=[{"source": file_path}]*len(text_chunks))

    # 步骤 2: 线上问答推理流程
    # 2.1 查询预处理改写
    rewrite_query = llm_query_rewrite(user_query)

    # 2.2 多路检索召回 Top5 文本块
    recall_chunks = vector_db.similarity_search(query=rewrite_query, k=5)

    # 2.3 重排序过滤低相关片段
    top_chunks = rerank_model.rerank(user_query, recall_chunks, top_n=3)

    # 2.4 拼接增强提示词
    prompt_template = """
    仅依据下方知识库内容回答用户问题，无匹配资料直接回复无相关信息，
    禁止编造内容，标注资料来源：
    知识库内容： {context}
    用户问题： {question}
    """
```

```

context_text = "\n".join([chunk["text"] for chunk in top_chunks])
final_prompt = prompt_template.format(context=context_text,
question=user_query)
# 2.5 LLM 生成回答
answer = llm.chat(final_prompt)
# 2.6 返回答案+引用来源
source_info = [chunk["source"] for chunk in top_chunks]
return {"answer": answer, "reference_source": source_info}

```

底层核心总结：离线构建向量知识库，线上检索上下文增强大模型输入，实现事实可靠问答。

11 RAG 专业术语词典

收录开发、面试、课程高频标准术语，释义精简易懂

RAG: 检索增强生成，外部知识库检索 + LLM 生成一体化架构

Chunk: 文本切片块，文档拆分后的最小检索单元

Embedding / 向量嵌入: 文本转为数字语义向量的编码模型

Vector Database: 向量数据库，存储文本向量、提供相似度检索

Metadata 元数据: 绑定文本块的文件、页码、标签等溯源信息

Top-K 召回: 检索阶段返回相似度最高的 K 条候选文本

Rerank 重排序: 交叉编码器模型对检索结果二次精准打分过滤

BM25: 传统关键词检索算法，用于多路召回融合

HyDE: 假设文档嵌入，优化短问句检索精度

Parent-Document Retrieval: 父子检索，解决切片上下文缺失问题

Agentic RAG: 智能体检索增强，融合 LLM-Agent 自主多轮检索

Graph RAG: 图谱增强 RAG，依托知识图谱实现实体关联多跳检索

Context Window 上下文窗口: 大模型单次可读取文本长度上限

Ingestion 索引构建: 离线索引阶段文档入库全流程

Multi-Retrieval 多路召回: 向量检索 + 关键词检索联合召回策略